

Fundamente Big Data

Predicția Valorii de Piață a Jucătorilor de Fotbal folosind Machine Learning

Proiect realizat de:

Horățău Darius Cristian

Varvara Dorin Robert

2026

Cuprins

1. INTRODUCERE	1
2. SELECȚIA DATELOR	1
2.1 JUSTIFICAREA SETULUI DE DATE	1
2.2 DESCRIEREA CARACTERISTICILOR	1
2.3 IDENTIFICAREA DATA LEAKAGE	2
2.4 VARIABILA ȚINTĂ	2
3. PREPROCESAREA DATELOR.....	3
3.1 GESTIONAREA VALORILOR LIPSĂ	3
3.2 ELIMINAREA DUPLICATELOR ȘI VALORILOR INVALIDE.....	3
3.3 ANALIZA ȘI DECIZIA PRIVIND OUTLIERII	3
3.4 TRANSFORMAREA LOGARITMICĂ A VARIABILEI ȚINTĂ	4
3.5 PIPELINE DE PREPROCESARE	5
4. TRANSFORMAREA DATELOR	5
4.1 ÎMPĂRȚIREA DATELOR ÎN SETURI DE ANTRENAMENT, VALIDARE ȘI TESTARE	5
4.2 SELECȚIA VARIABILELOR	5
4.3 SETURILE DE DATE FINALE	7
5. MODELELE DE MACHINE LEARNING.....	7
5.1 FUNCȚIA DE EVALUARE.....	7
5.2 MODELUL 1 — REGRESIA LINIARĂ (BASELINE)	7
5.3 MODELUL 2 — RANDOM FOREST REGRESSOR	9
5.4 MODELUL 3 — GRADIENT BOOSTING REGRESSOR	11
5.5 COMPARAREA CROSS-VALIDATION	12
6. EVALUAREA MODELELOR	13
6.1 COMPARAREA MODELELOR PE SETUL DE VALIDARE	13
6.2 ANALIZA OVERFITTING/UNDERFITTING	13
6.3 KDD PASUL 8: REANTRENAREA MODELULUI FINAL	14
6.4 EVALUAREA FINALĂ PE SETUL DE TEST	14
6.5 ANALIZA PREDICȚIILOR: GRAFICE DE EVALUARE	15
6.6 VERIFICAREA NORMALITĂȚII REZIDUURILOR: QQ-PLOT	16
6.7 ANALIZA CELOR MAI MARI ERORI DE PREDICȚIE	16
7. CONCLUZII, LIMITĂRI ȘI APLICAȚII	17
7.1 REZULTATELE FINALE	17
7.2 COMPARAREA MODELELOR	17
7.3 PUNCTE FORTE.....	18
7.4 LIMITĂRI	19

1. Introducere

Industria fotbalului profesionist generează anual transferuri de jucători în valoare de miliarde de euro, iar estimarea corectă a valorii de piață a unui jucător reprezintă un avantaj competitiv major pentru cluburi, agenți și investitori. Valoarea de piață este influențată de o multitudine de factori: performanțele sportive, vârsta, potențialul de dezvoltare, poziția pe teren și reputația internațională, ceea ce face estimarea manuală dificilă și subiectivă.

Acest proiect își propune construirea unui model de Machine Learning capabil să prezică valoarea de piață a jucătorilor de fotbal pe baza caracteristicilor lor sportive și demografice, urmând procesul Knowledge Discovery in Database.

Setul de date utilizat este *FIFA 22 Complete Player Dataset*, disponibil public pe platforma Kaggle (autor: stefanoleone992), conținând **19.239 de jucători** descriși prin **110 attribute** extrase din jocul video FIFA 22 al EA Sports. Variabila țintă este `value_eur`: valoarea de piață estimată în euro, cu valori cuprinse între 9.000 EUR și 194.000.000 EUR.

Tipul sarcinii este predicție numerică, deoarece variabila țintă este continuă. Au fost comparate trei modele de regresie: Regresia Liniară (model baseline), Random Forest Regressor și Gradient Boosting Regressor.

2. Selecția Datelor

2.1 Justificarea setului de date

Setul de date *FIFA 22 Complete Player Dataset* a fost ales datorită mai multor avantaje: este disponibil public pe Kaggle, conține un număr mare de înregistrări (19.239 jucători), acoperă o gamă largă de attribute relevante pentru valoarea de piață și include jucători din ligi și naționalități diverse. Variabila țintă `value_eur` este disponibilă pentru marea majoritate a jucătorilor, cu doar 74 valori lipsă (0.38%).

2.2 Descrierea caracteristicilor

Din cele 110 coloane disponibile, au fost selectate 21 de feature-uri grupate în cinci categorii:

- Caracteristici fizice și demografice: `age`, `height_cm`, `weight_kg`
- Context competițional: `nationality_name`, `club_name`, `league_name`
- Stil de joc: `player_positions`, `preferred_foot`, `work_rate`

- Rating FIFA: overall, potential, international_reputation, weak_foot, skill_moves
- Financiar: wage_eur
- Statistici tehnice: pace, shooting, passing, dribbling, defending, physic

2.3 Identificarea Data Leakage

Analiza corelațiilor a evidențiat că variabila `release_clause_eur` are o corelație de 0.995 cu `value_eur` care este aproape perfectă. Aceasta se datorează faptului că clauza de reziliere este calculată direct din valoarea de piață a jucătorului. Includerea ei în model ar reprezenta data leakage, modelul ar "trișa" folosind o variabilă care conține implicit informația pe care trebuie să o prezică. Prin urmare, `release_clause_eur` a fost exclusă din proiect.




Figura 1: Heatmap corelații

2.4 Variabila țintă

`value_eur` prezintă o distribuție puternic asimetrică spre dreapta, cu o asimetrie (*skewness*) de 8.19. Mediana valorilor este de 975.000 EUR, în timp ce media este de 2.850.000 EUR, diferență semnificativă cauzată de prezența câtorva jucători cu valori extreme (ex: Kylian Mbappé = 194.000.000 EUR). Această asimetrie motivează aplicarea transformării logaritmice `log1p` în etapa de transformare a datelor.

3. Preprocesarea Datelor

3.1 Gestionarea valorilor lipsă

După eliminarea celor 74 de rânduri fără valoare țintă (`value_eur`), dataset-ul conține 19.165 înregistrări. Analiza valorilor lipsă în cele 21 de feature-uri selectate a relevat un singur tip de valori lipsă: coloanele `pace`, `shooting`, `passing`, `dribbling`, `defending` și `physic` au fiecare 2.124 valori lipsă (11.08%).

Aceste valori lipsă aparțin exclusiv portarilor, aceștia nu au statistici tehnice de câmp în FIFA 22. Strategia aleasă este imputarea cu mediana prin **SimpleImputer**, realizată automat în interiorul pipeline-ului de preprocesare. Eliminarea portarilor nu a fost luată în considerare deoarece aceștia reprezintă o categorie validă de jucători cu valori de piață semnificative.

3.2 Eliminarea duplicatelor și valorilor invalide

Verificarea dataset-ului a confirmat absența rândurilor duplicate (0 duplicate identificate). De asemenea, nu au existat valori zero sau negative în variabila țintă `value_eur`, astfel că nicio înregistrare suplimentară nu a fost eliminată în această etapă.

3.3 Analiza și decizia privind outlierii

Analiza boxplot-urilor pentru variabilele cheie (`value_eur`, `age`, `overall`, `wage_eur`) a evidențiat prezența outlierilor, în special în `value_eur` și `wage_eur`. Decizia adoptată este păstrarea outlierilor, justificată prin trei argumente:

- Jucătorii cu valori extreme (Mbappé, Haaland, De Bruyne) sunt reali și relevanți pentru model, eliminarea lor ar produce un model incapabil să estimeze valori ridicate
- Modelele bazate pe arbori de decizie (Random Forest, Gradient Boosting) sunt robust la prezența outlierilor prin natura lor
- Transformarea `log1p` aplicată pe variabila țintă reduce semnificativ impactul valorilor extreme asupra funcției de cost




Figura 2: Boxploturi variabile cheie: outlierii sunt păstrați

3.4 Transformarea logaritmică a variabilei țintă

Variabila țintă `value_eur` prezintă o asimetrie de 8.19, indicând o distribuție puternic înclinată spre dreapta. Aplicarea transformării $\log_{1p}(x) = \log(1 + x)$ reduce asimetria la 0.59, producând o distribuție aproape normală.

Această transformare este esențială deoarece:

- Modelele de regresie performează mai bine când variabila țintă este aproape normal distribuită
- Reduce influența outlierilor asupra estimării parametrilor
- Predicțiile finale sunt transformate înapoi la scala EUR prin funcția inversă $\expm1(y) = \exp(y) - 1$




Figura 3: Distribuția `value_eur`

3.5 Pipeline de preprocesare

Pentru a evita partajarea stării interne între modele diferite, a fost implementată o funcție `create_preprocessor()` care returnează o instanță independentă a preprocessorului la fiecare apel. Pipeline-ul aplică:

- **Coloane numerice:** imputare cu mediana - `StandardScaler`
- **Coloane categorice:** imputare cu valoarea cea mai frecventă - `OneHotEncoder` (`handle_unknown="ignore"`)

4. Transformarea Datelor

4.1 Împărțirea datelor în seturi de antrenament, validare și testare

Datele au fost împărțite în trei seturi distincte, conform procesului KDD:

- Training (70% = 13.422 exemple): utilizat pentru estimarea parametrilor modelului
- Validare (15% = 2.868 exemple): utilizat pentru alegerea hiperparametrilor și compararea modelelor. Setul de validare permite selectarea modelului final fără a "contamina" setul de test
- Test (15% = 2.875 exemple): utilizat exclusiv pentru evaluarea finală a performanței, o singură dată, după selectarea modelului final

Împărțirea a fost realizată în două etape folosind `train_test_split` cu `random_state=42` pentru reproductibilitate. Suplimentar, a fost păstrat `X_trainval` (85% = 16.290 exemple).

4.2 Selecția variabilelor

Includerea variabilelor irelevante poate duce la overfitting, dificultăți de interpretare și ineficiență computațională. Pentru identificarea variabilelor relevante a fost utilizată metoda importanței variabilelor din Random Forest.

Metodologie: Un Random Forest preliminar a fost antrenat exclusiv pe setul de training (`X_train`) pentru a evita data leakage. Importanțele variabilelor encodeate (după One-Hot Encoding) au fost agregate per variabilă originală, iar variabilele cu importanță peste pragul de 0.001 au fost selectate.

Rezultate selecție = Din cele 21 de feature-uri inițiale, au fost selectate 8 variabile:

<u>Variabilă</u>	<u>Importanță</u>	<u>Interpretare</u>
overall	75.5%	Ratingul general FIFA = cel mai puternic predictor
potential	18.1%	Potențialul de dezvoltare
age	5.0%	Vârsta jucătorului
skill_moves	0.4%	Numărul de fente
player_positions	0.4%	Poziția pe teren
shooting	0.2%	Abilitatea de șut
dribbling	0.1%	Abilitatea de dribling
defending	0.1%	Abilitatea defensivă

Au fost eliminate 13 variabile cu importanță sub pragul de 0.001, inclusiv wage_eur (0.04%), club_name (0.02%) și league_name (0.02%). Deși wage_eur are o corelație ridicată cu value_eur (0.82), în prezența variabilei overall nu mai aduce informație suplimentară semnificativă pentru model.




Figura 4: Importanța variabilelor originale

4.3 Seturile de date finale

După selecția variabilelor, dimensiunile seturilor sunt:

Set	Exemple	Feature-uri
X_train_sel	13422	8
X_val_sel	2868	8
X_test_sel	2875	8
X_trainval_set	16290	8

5. Modelele de Machine Learning

5.1 Funcția de evaluare

Toate modelele sunt evaluate folosind patru metrice calculate în scala originală EUR, după aplicarea funcției inverse `expm1` asupra predicțiilor din spațiul logaritmic:

- MAE (Mean Absolute Error) = eroarea medie absolută, ușor de interpretat în EUR
- MSE (Mean Squared Error) = eroarea pătratică medie, penalizează erorile mari mai puternic
- RMSE (Root Mean Squared Error) = rădăcina erorii pătratice medii, în aceeași unitate ca targetul (EUR)
- R² (Coeficientul de determinare) = proporția din varianța targetului explicată de model (1 = perfect, 0 = model trivial)

Fiecare model este evaluat pe trei seturi: Train, Validare și Test.

5.2 Modelul 1: Regresia Liniară (baseline)

Regresia liniară multivariată estimează relația liniară dintre cei 8 predictorii originali (expandați în 607 coloane după One-Hot Encoding) și variabila țintă transformată logaritmic:

$$\log1p(value_eur) = w_0 + w_1 \cdot X_1 + w_2 \cdot X_2 + \dots + w_p \cdot X_p$$

Modelul nu are hiperparametri de optimizat, parametrii sunt estimați direct prin metoda celor mai mici pătrate (OLS). Servește drept model baseline pentru compararea cu modelele mai complexe.

Ecuatia obținută după antrenare:

$$\log_{10}(\text{value_eur}) = 13.9064 + (1.2986) \cdot \text{overall} + (-0.5558) \cdot \text{age} + (0.0492) \cdot \text{defending} + (0.0399) \cdot \text{skill_moves} + (0.0186) \cdot \text{shooting} + \dots$$

Interpretarea coeficienților principali:

Feature	Coeficient	Interpretare
overall	+1.2986	Fiecare punct în plus la overall crește $\log_{10}(\text{value_eur})$ cu 1.30
age	-0.5558	Fiecare an în plus scade $\log_{10}(\text{value_eur})$ cu 0.56
defending	+0.0492	Efect pozitiv mic: apărarea bună crește valoarea
skill_moves	+0.0399	Jucătorii cu mai multe fente valorează ușor mai mult
shooting	+0.0186	Efect pozitiv mic: abilitatea de șut crește valoarea
Poziții atacante (CF, LW, RW)	+0.45 la +0.67	Atacanții valorează semnificativ mai mult
Poziții defensive (CDM, CB)	-0.49 la -0.50	Fundașii valorează mai puțin la același overall

Cross-validare (5-fold): $R^2 = 0.9634 \pm 0.0010$

Performanța:

Set	MAE (EUR)	MSE (EUR ²)	RMSE (EUR)	R ²
Train	647.443	5.695T	2.386.506	0.9027
Validare	740.609	7.231T	2.689.200	0.8701
Test	646.359	6.066T	2.463.095	0.8947

Diferența mică între Train ($R^2=0.90$) și Validare ($R^2=0.87$) indică absența overfitting-ului. Totuși, $R^2=0.87$ pe validare sugerează că relațiile neliniare din date nu pot fi capturate complet de un model liniar, justificând utilizarea modelelor mai complexe.




Figura 5: Top 15 coeficienți ai regresiei liniare.

5.3 Modelul 2: Random Forest Regressor

Random Forest construiește un număr mare de arbori decizionali pe subseturi aleatorii ale datelor și predictorilor, agregând predicțiile prin medie. Scopul principal este **reducerea varianței** față de un arbore individual.

Optimizarea hiperparametrilor GridSearchCV:

A fost utilizat GridSearchCV cu 3-fold cross-validare pe un grid redus pentru eficiență computațională (18 combinații $\times$ 3 folduri = 54 fits):

Hiperparametru	Valori testate	Optim selectat
n_estimators	50, 100, 200	Ajustat 300
max_depth	10, 20, None	None - ajustat la 8
min_samples_leaf	1, 5	Ajustat la 10

GridSearchCV a selectat inițial max_depth=None, însă analiza learning curve a evidențiat un gap între Train și Validare. max_depth a fost ajustat la 8, min_samples_leaf la 10 și n_estimators la 300 pentru a reduce overfitting-ul vizibil în learning curve.

OOB Error: Eroarea Out-of-Bag pornește de la 1.27 cu 10 arbori, scade dramatic până la ~25 de arbori și se stabilizează complet după aceea. Acest grafic justifică alegerea lui $n_{\text{estimators}}=200$, eroarea nu mai scade semnificativ după 50 de arbori, dar 200 asigură stabilitate maximă.




Figura 6: Training Error vs. OOB Error pe număr de arbori

Learning Curve: Gap constant între Train (~0.0002) și Validare (~0.0017), overfitting cauzat de arborii individuali care memorează subseturile bootstrap. Adăugarea de arbori nu reduce acest gap, overfitting-ul este structural, nu dependent de numărul de arbori.




Figura 7: Learning Curve Random Forest

Cross-validare (5-fold): $R^2 = 0.9974 \pm 0.0003$

Performanța:

Set	MAE (EUR)	MSE (EUR ²)	RMSE (EUR)	R ²
Train	105.167	263B	512.848	0.9955
Validare	157.374	930B	964.394	0.9833
Test	175.604	3.436T	1.853.679	0.9403

5.4 Modelul 3: Gradient Boosting Regressor

Gradient Boosting construiește arbori **secvențial**, fiecare corectând erorile modelului anterior prin antrenare pe reziduuri. Spre deosebire de Random Forest care construiește arbori independent (paralel) și reduce varianța, Gradient Boosting **reduce bias-ul** prin îmbunătățiri succesive ale predicției.

Optimizarea hiperparametrilor GridSearchCV:

A fost utilizat GridSearchCV cu 3-fold cross-validare (16 combinații × 3 folduri = 48 fits):

Hiperparametru	Valori testate	Optim selectat
n_estimators	100, 200	200
learning_rate	0.05, 0.1	0.1
max_depth	3, 5	5
min_samples_leaf	1, 5	5

Learning Curve: Spre deosebire de Random Forest, liniile Train și Validare sunt practic suprapuse pe tot parcursul antrenării, niciun gap vizibil. Ambele scad rapid în primele 25-30 de iterații și se stabilizează după 75-100. Gradient Boosting generalizează excelent pe acest dataset, fără overfitting semnificativ.




Figura 8: Learning Curve Gradient Boosting

Early Stopping: Cu parametrii `n_iter_no_change=10` și `validation_fraction=0.1`, modelul s-a oprit la **81 de iterații** din 500 maxime, economisind 419 iterații inutile. Aceasta confirmă vizual ce arată learning curve-ul: după ~80 de iterații nu mai există îmbunătățire semnificativă pe setul de validare intern.

Cross-validare (5-fold): $R^2 = 0.9981 \pm 0.0002$

Performanța:

Set	MAE (EUR)	MSE (EUR ²)	RMSE (EUR)	R ²
Train	97.690	121B	348.653	0.9979
Validare	125.815	243B	493.044	0.9956
Test*	125.233	767B	876.203	0.9867

5.5 Compararea Cross-Validation

Model	CV R ² Medie	CV R ² Std
Linear Regression	0.9634	0.0010
Random Forest	0.9974	0.0003
Gradient Boosting	0.9981	0.0002

6. Evaluarea Modelelor

6.1 Compararea modelelor pe setul de Validare

Alegerea modelului final s-a realizat exclusiv pe baza performanței pe setul de validare, fără a utiliza setul de test în această etapă.

Model	MAE (EUR)	MSE (EUR ²)	RMSE (EUR)	R ²
Gradient Boosting	125.815	243B	493.044	0.9956
Random Forest	157.374	930B	964.394	0.9833
Linear Regression	740.609	7.231T	2.689.200	0.8701

Gradient Boosting obține cel mai mic RMSE (493.044 EUR) și cel mai mare R² (0.9956) pe setul de validare, fiind selectat ca **model final**.

6.2 Analiza Overfitting/Underfitting

Compararea performanței pe Train vs. Validare pentru cele trei modele:

Model	R ² Train	R ² Validare	Diferență	Concluzie
Gradient Boosting	0.9979	0.9956	0.0023	Fără overfitting
Random Forest	0.9955	0.9833	0.0122	Overfitting moderat
Linear Regression	0.9027	0.8701	0.0326	Underfitting ușor

Model	RMSE Train	RMSE Validare	Diferență
Gradient Boosting	348.653 EUR	493.044 EUR	+144.391 EUR
Random Forest	512.848 EUR	964.394 EUR	+451.546 EUR
Linear Regression	2.386.506 EUR	2.689.200 EUR	+302.694 EUR




Figura 9: Compararea modelelor pe setul de Validare

Interpretare:

- Gradient Boosting: diferență minimă Train-Validare pe ambele metrice. Modelul generalizează excelent, confirmând că construcția secvențială reduce bias-ul fără a produce overfitting
- Random Forest: gap mai mare la RMSE (512K vs. 964K). Overfitting cauzat de arborii individuali care memorează subseturile bootstrap, redus prin impunerea `max_depth=8`
- Linear Regression: erori ridicate pe ambele seturi, indică că relațiile dintre variabile sunt neliniare și nu pot fi capturate complet de un model liniar

6.3 KDD Pasul 8: Reentrenarea modelului final

Conform procesului KDD, după selectarea modelului final pe setul de validare, acesta a fost reentrenat pe întregul set de antrenament disponibil: Train + Validare = 16.290 exemple (85% din date). Aceasta maximizează cantitatea de date folosită pentru antrenament înainte de evaluarea finală pe test.

Parametrii folosiți sunt cei identificați prin GridSearchCV:

- `learning_rate = 0.1`
- `max_depth = 5`
- `min_samples_leaf = 5`
- `n_estimators = 200`

6.4 Evaluarea finală pe setul de test

Setul de test a fost utilizat o singură dată, după reentrenarea modelului final, pentru a estima performanța reală pe date complet noi, neobservate în nicio etapă anterioară.

Model	MAE (EUR)	MSE (EUR ²)	RMSE (EUR)	R ²
Gradient Boosting	125.233	767B	876.203	0.9867
Random Forest	175.604	3.436T	1.853.679	0.9403
Linear Regression	646.359	6.066T	2.463.095	0.8947

Gradient Boosting rămâne cel mai performant model și pe setul de test, confirmând că selecția pe validare a fost corectă.




Figura 10: Analiza Overfitting/Underfitting

6.5 Analiza predicțiilor: Grafice de evaluare

Graficul valori reale vs. valori prezise arată că punctele urmează foarte bine linia diagonală roșie (predicție perfectă), în special pentru jucătorii cu valori mici și medii (sub 50M EUR). Există câteva abateri vizibile pentru jucătorii cu valori extreme — cel mai notabil este Kylian Mbappé (valoare reală 194M EUR, prezis 154M EUR).

Graficul rezidual arată că reziduurile sunt centrate în jurul valorii 0 pentru predicțiile mici, cu o dispersie crescătoare pentru predicțiile mari — fenomen cunoscut ca heteroscedasticitate. Aceasta indică faptul că modelul este mai precis pentru jucătorii cu valori mici și mai puțin precis pentru jucătorii foarte valoroși.

Distribuția reziduurilor prezintă o formă îngustă centrată în 0, cu o coadă lungă spre dreapta, cauzată de câțiva jucători cu erori mari de predicție.

6.6 Verificarea normalității reziduurilor: QQ-Plot

QQ-Plot-ul în scala logaritmică arată că punctele urmează bine linia diagonală în zona centrală, cu devieri la extreme, distribuție aproape normală pentru marea majoritate a observațiilor.

Testul Shapiro-Wilk (n=500) confirmă:

- Statistica $W = 0.9928$, foarte aproape de 1, indicând o distribuție aproape normală
- $p\text{-value} = 0.017$, respinge tehnic normalitatea perfectă, însă pentru seturi mari de date testul Shapiro-Wilk este extrem de sensibil. O valoare $W = 0.9928$ este considerată acceptabilă în practică.

6.7 Analiza celor mai mari erori de predicție

overall potential age			Poziție	Valoare reală	Valoare prezisă	Eroare
91	95	22	ST, LW	194.000.000	154.177.600	39.822.400
84	89	25	GK	49.500.000	61.129.450	11.629.450
83	89	22	CB	53.000.000	61.954.430	8.954.430
84	90	23	LB	62.500.000	68.858.290	6.358.290
87	87	31	CAM	66.000.000	60.078.520	5.921.480

Interpretare:

- Primul rând este cu certitudine Kylian Mbappé, cel mai valoros jucător din dataset. Eroarea de 39.8M EUR reprezintă o eroare relativă de ~20%, explicabilă prin faptul că există extrem de puțini jucători la acest nivel de valoare în dataset
- Rândurile 2-4, jucători tineri (22-25 ani) cu potential ridicat (89-90). Modelul subestimează ușor acești jucători, probabil deoarece potențialul ridicat la vârstă mică este rar în dataset
- Rândul 5 este jucător de 31 de ani cu overall ridicat (87). Modelul supraevaluează ușor jucătorii în vârstă cu rating bun

7. Concluzii, Limitări și Aplicații

7.1 Rezultatele finale

Performanța celor trei modele pe setul de test:

Model	MAE (EUR)	RMSE (EUR)	R ²
Gradient Boosting	125.233	876.203	0.9867
Random Forest	175.604	1.853.679	0.9403
Linear Regression	646.359	2.463.095	0.8947

Modelul final selectat este Gradient Boosting Regressor, cu parametrii `learning_rate=0.1`, `max_depth=5`, `min_samples_leaf=5`, `n_estimators=200`, obținând un R² de 0.9867 pe setul de test.




Figura 11: Compararea modelelor

7.2 Compararea modelelor

Gradient Boosting a depășit celelalte modele pe toate metricile datorită construcției secvențiale care reduce bias-ul prin corectarea erorilor iterativ. Cross-validarea (5-fold) a confirmat stabilitatea sa cu $R^2 = 0.9981 \pm 0.0002$, cea mai mică variabilitate dintre cele trei modele. Early stopping a demonstrat că modelul converge după doar 81 de iterații din 500 maxime, confirmând eficiența algoritmului.

Random Forest a prezentat un gap Train-Validare mai pronunțat la RMSE (512K vs. 964K EUR), iar Regresia Liniară a confirmat că relațiile dintre variabile sunt preponderent neliniare, $R^2=0.87$ pe validare reprezentând plafonul unui model liniar pe aceste date.

7.3 Puncte forte

Modelul obține acuratețe ridicată pentru jucătorii cu valoare medie (sub 50M EUR), segmentul dominant al pieței transferurilor. Performanța consistentă între validare ($R^2=0.9956$) și test ($R^2=0.9867$) confirmă că modelul generalizează bine pe date noi. Procesul KDD complet incluzând selecția variabilelor, optimizarea hiperparametrilor prin GridSearchCV și reantrenarea pe 85% din date, asigură robustețea rezultatelor.




Figura 12: Valori reale vs. prezise, grafic rezidual și distribuția reziduurilor — Gradient Boosting, setul de Test




Figura 13: QQ-Plot reziduuri în scala log și scala EUR: Gradient Boosting




Figura 14: Importanța variabilelor în modelul final Gradient Boosting

7.4 Limitări

Erorile cele mai mari apar pentru jucătorii cu valori extreme: Mbappé (194M EUR) a fost prezis la 154M EUR, eroare de ~20%, cauzată de numărul insuficient de exemple similare în dataset. În plus, valoarea de piață reală este influențată de factori neincluși în datele FIFA 22: forma recentă, accidentări, durata contractului rămasă și contextul negocierilor de transfer. Nu în ultimul rând, dominanța variabilei overall (75.5% importanță) reflectă o limitare a sursei de date, ratingurile FIFA sunt subiective și pot să nu reflecte cu exactitate performanța reală a jucătorilor.